合肥工業大學
HEFEI UNIVERSITY OF TECHNOLOGY

人工智能安全

对抗攻击与防御

刁云峰

diaoyunfeng@hfut.edu.cn

目 录

CONTENTS

01| Background（背景）
AI对抗攻防背景介绍

02| Literatures（相关实例）
AI对抗攻防的相关实例

03| Methods（攻防原理）
AI对抗攻防部分算法原理

01| Background（背景）

AI对抗攻防背景介绍

人工智能安全的研究背景

问题挑战

可用性	● 异常输入 ● 物理扰动 ● 恶意破坏
完整性	● 恶意植入 ● 模型篡改 ● 数据伪造
鲁棒性	● 对抗样本 ● 投毒攻击 ● 后门攻击
隐私性	● 模型窃取 ● 模型反演 ● 成员隐私

深度学习隐私性:是指在数据原始信息没有发生直接泄露的情况下，深度学习模型计算过程产生的信息不会间接暴露训练集数据、模型参数和预测样例。机器学习算法中的隐私问题严重阻碍了机器学习技术的普适推广。

深度学习鲁棒性:是指现有深度学习方法的有效性不依赖于对数据的高质量要求，当训练集呈现蕴含复杂噪声、异常点入侵、类别不均衡等或当测试集存在人为扰动、与异常输入等问题时，其有效性仍能保证。

研究人工智能安全具有重要意义!

人工智能安全的技术内涵

不可解释性 → 黑箱模型 →

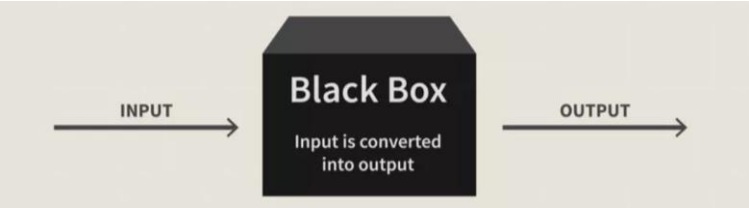

数据强依赖性 → 数据偏差和噪声 →

数据强依赖性 → 对抗样本攻击 →

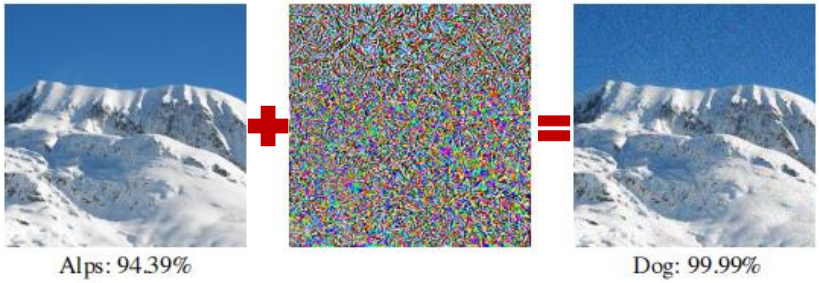

90年代的媒體：
人工智能會在十年內毀掉社會

現在的人工智能：

Machine Learning in Physical World

Autonomous Driving

Healthcare

Smart City

Malware Classification

Fraud Detection

Biometrics Recognition

Deep fake 动态换脸

Physical Adversarial Attacks Against Sensor Fusion

Goal: we aim to generate physical **adversarial object** against **real-world LiDAR system**.

LiDAR-based perception

Physical Experiments

Adversarial object/benign box **in the middle**

Benign Object

Adversarial Object

清华最新研究成果：一副眼镜破解 19 款安卓手机人脸识别系统

2021-01-28 22:50:35 来源: IT之家 举报

3

分享至

IT之家 1 月 28 日消息 根据清华大学人工智能研究院设立的人工智能企业瑞莱智慧 RealAI 的消息，研究人员通过对抗样本攻击，破解了 19 款安卓手机的人脸识别解锁系统。

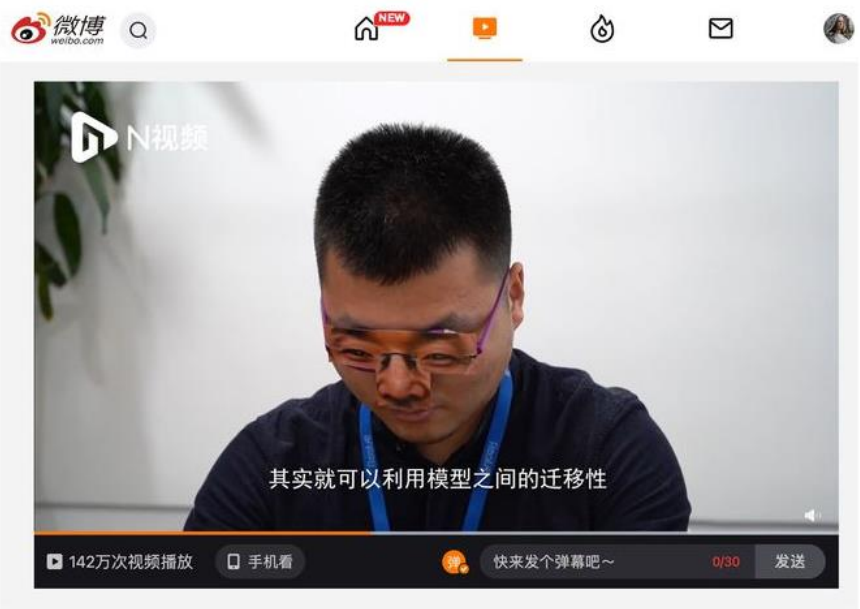

研究人员表示，第一步需要拿到攻击目标的照片，然后用优化算法生成对抗样本，然后把贴纸裁下来，贴在眼镜框上就可以了。

官方表示，他们选取了从低端到高端的 19 款安卓手机和 1 款 iPhone 11 进行了测试，除了 iPhone 11 之外，其他的手机都能在 15 分钟之内被破解。另外，研究人员还用抗样本攻击了几款政务和金融 App 的人脸识别系统，甚至假冒机主完成了银行开户。

对抗样本是指对原始的输入样本添加精心设计的细微扰动致使机器学习模型输出错误的结果。神经网络因为极易受到对抗样本的威胁而导致其安全问题备受关注。对抗攻击生成的扰动极其微小，人类用肉眼几乎无法察觉，但是对当前的人工智能系统却会造成破坏性的影响，

目前对抗样本已经被证明可以适用到各种视觉分类的任务中，造成重大的安全隐患。例如图1展示了利用对抗样本原理设计的3D眼镜可以破解手机的人脸识别解锁系统，导致财产损失和隐私泄露。由此可见对抗攻击对视觉分类器带来的巨大安全威胁使得研发鲁棒性视觉分类器具有重大现实意义，对人工智能安全的发展具有重要科研价值。

国际背景

2018 年，根据美国《国防授权法案 2019》美国国家人工智能安全委员会（NSCAI）在美国国防部的支持下正式成立。

该委员会的职能在于代表国会研究人工智能与国家安全的相关问题并建言献策，以达到确保美国技术优势的最终目的。

2021年，欧盟提出《人工智能法规草案》

AI安全方向分类

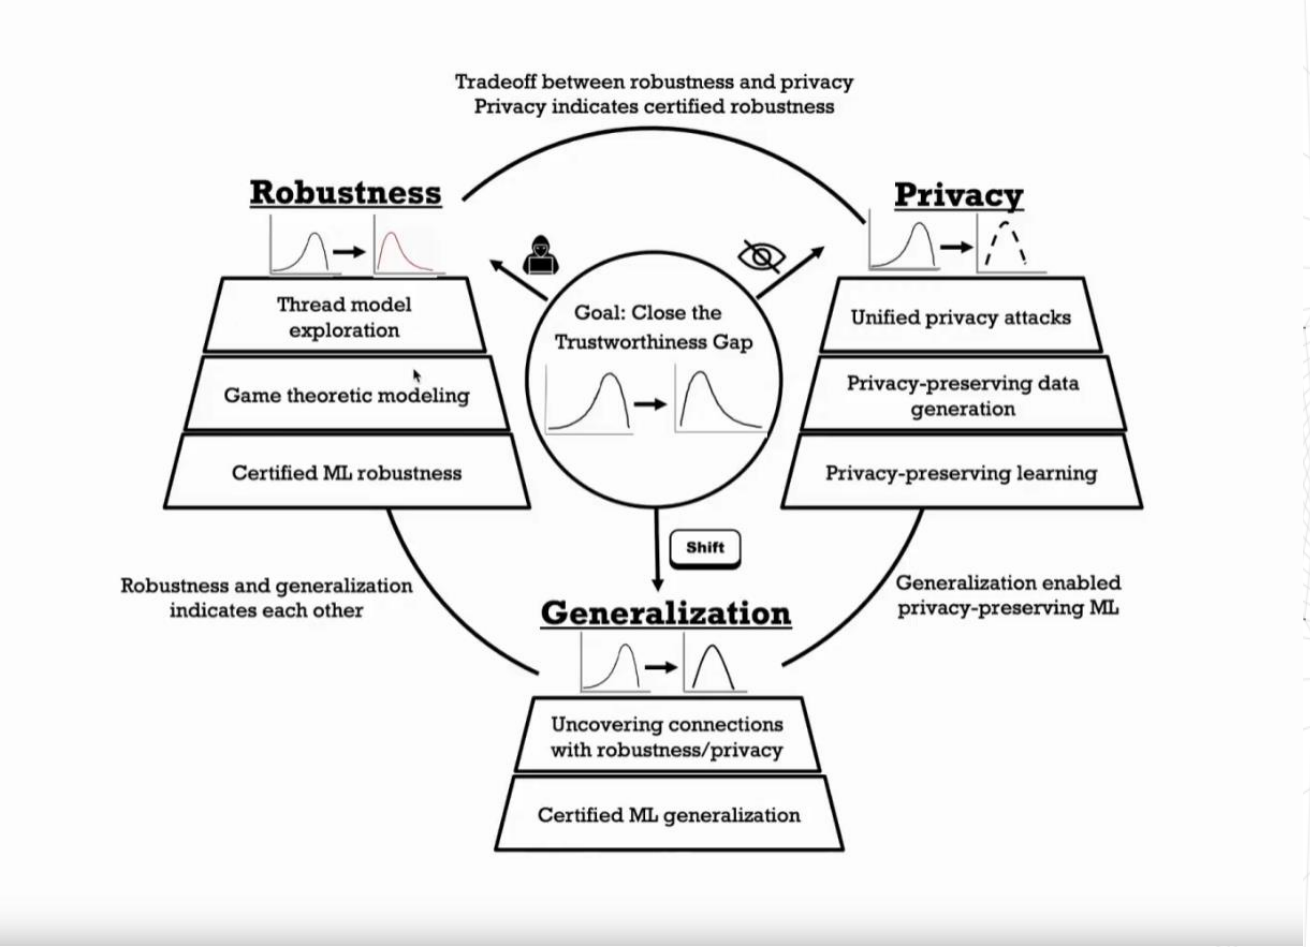
Tradeoff between robustness and privacy
Privacy indicates certified robustness
Robustness
Privacy
Thread model exploration
Game theoretic modeling
Certified ML robustness
Goal: Close the Trustworthiness Gap
Unified privacy attacks
Privacy-preserving data generation
Privacy-preserving learning
Shift
Robustness and generalization indicates each other
Generalization
Generalization enabled privacy-preserving ML
Uncovering connections with robustness/privacy
Certified ML generalization

02| Literatures（相关实例）

AI对抗攻防的相关实例

对抗攻防相关实例

■ AI算法：易受“微小”扰动影响

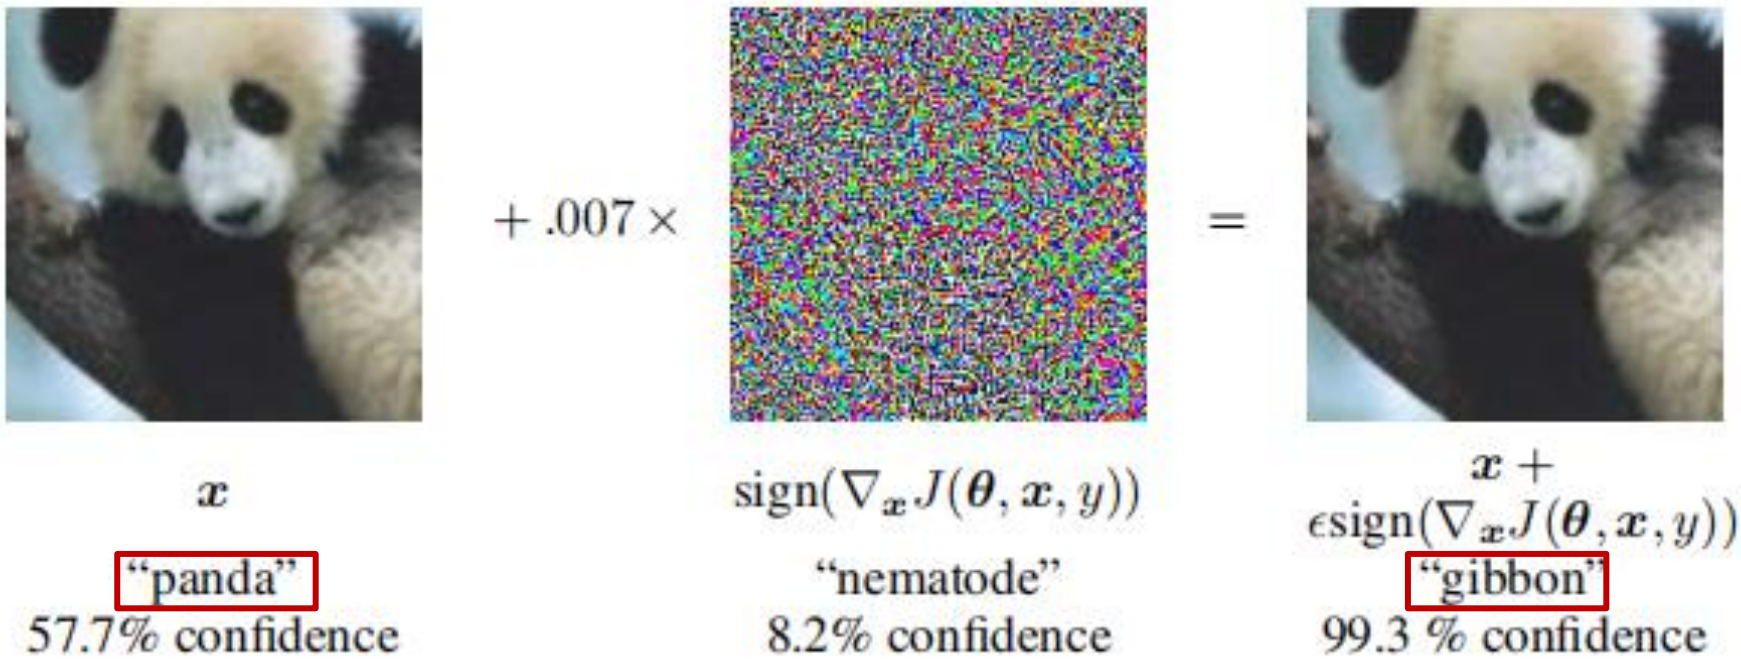

Adversarial perturbation: The noise that is added to the clean image to make it an adversarial example.

[1] Goodfellow, 1. J., Shlens, J., and Szegedy, C. Explaining and harnessing adversarial examples. 2015 ICLR.

对抗攻防相关实例

- “微小”扰动：人类难以识别

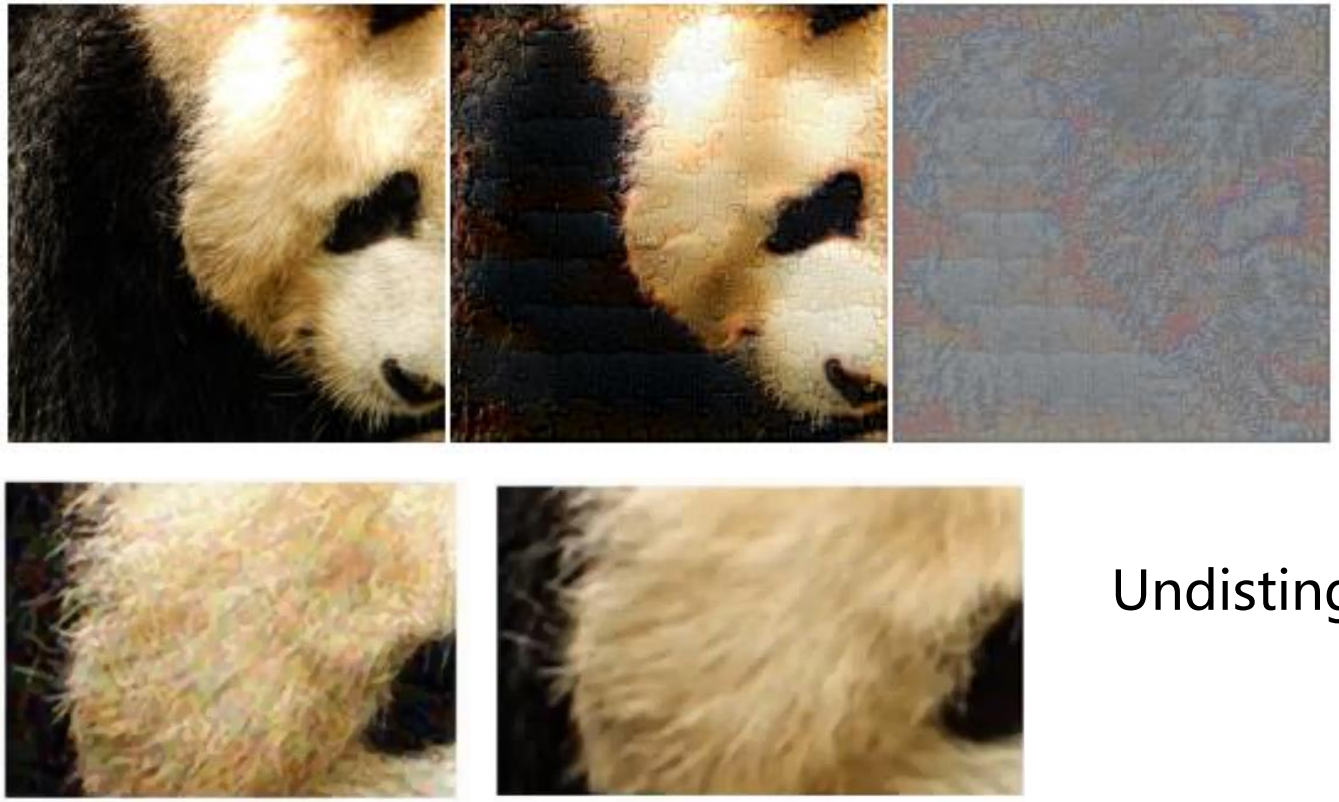

Undistinguishable?

[2]Alexey Kurakin et al. Adversarial Attacks and Defenses Competition, 2017 NeurIPS

How can they be used to compromise machine learning?

Fool the self-driven system

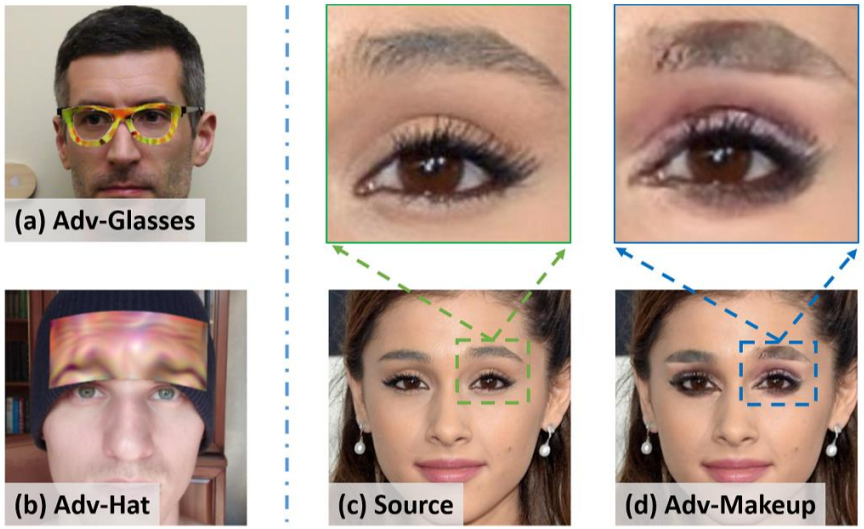

Deceive face recognition

对抗攻防相关实例

■ 单像素攻击：仅改变图片一个像素

[3] Jiawei Su et al. One Pixel Attack for Fooling Deep Neural Networks. 2019 TEC.

对抗攻防相关实例

■ 医学领域：医学影像图片识别干扰

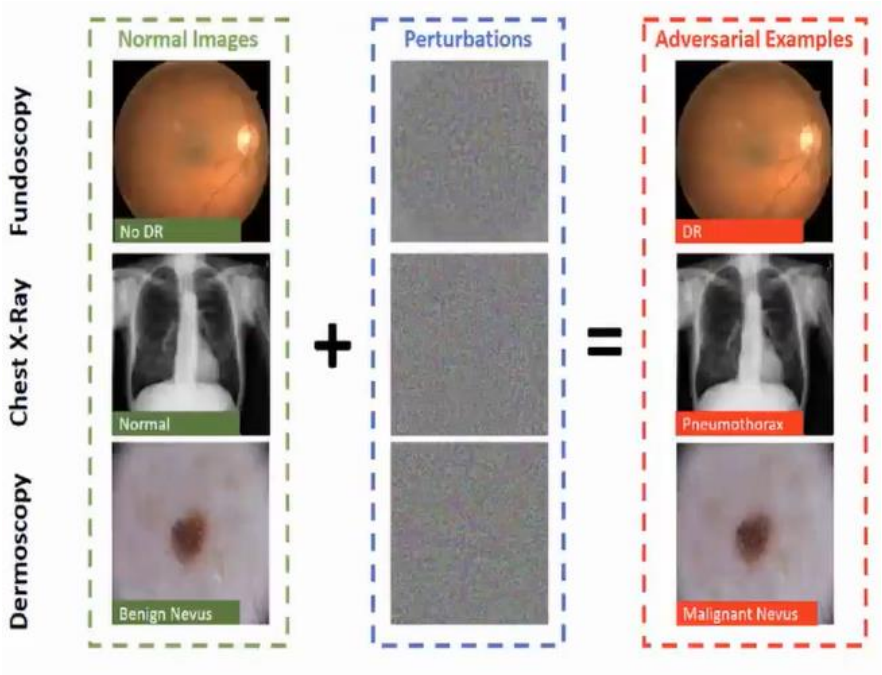

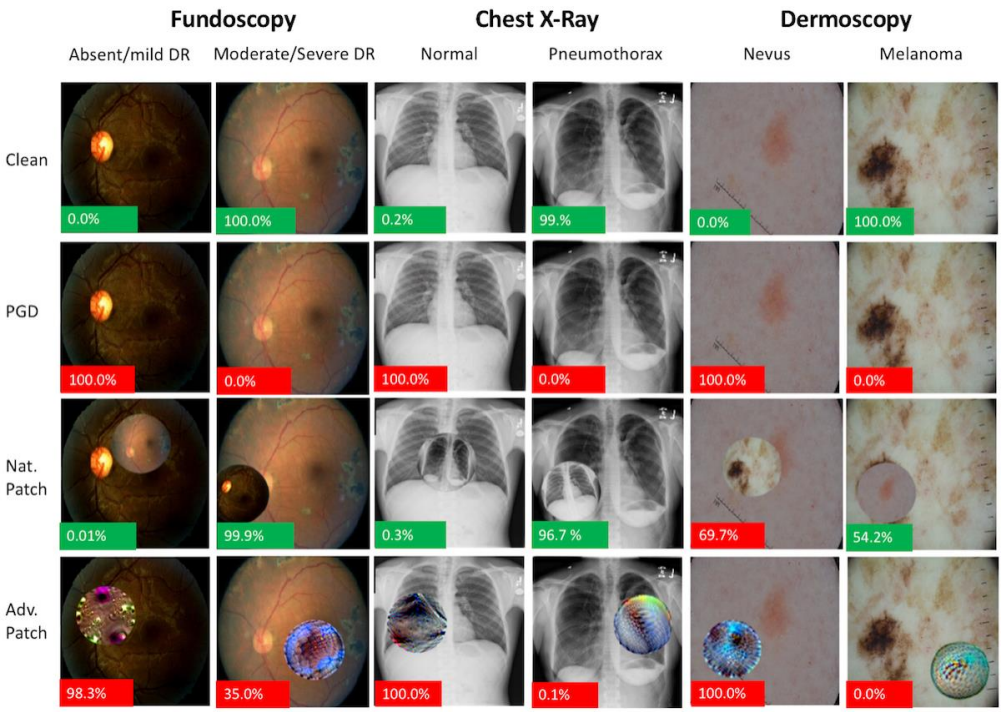

[4] Samuel G, Finlayson et al. Adversarial Attacks Against Medical Deep Learning Systems. 2019

对抗攻防相关实例

- 目标检测：视频中添加扰动——攻击前与攻击后

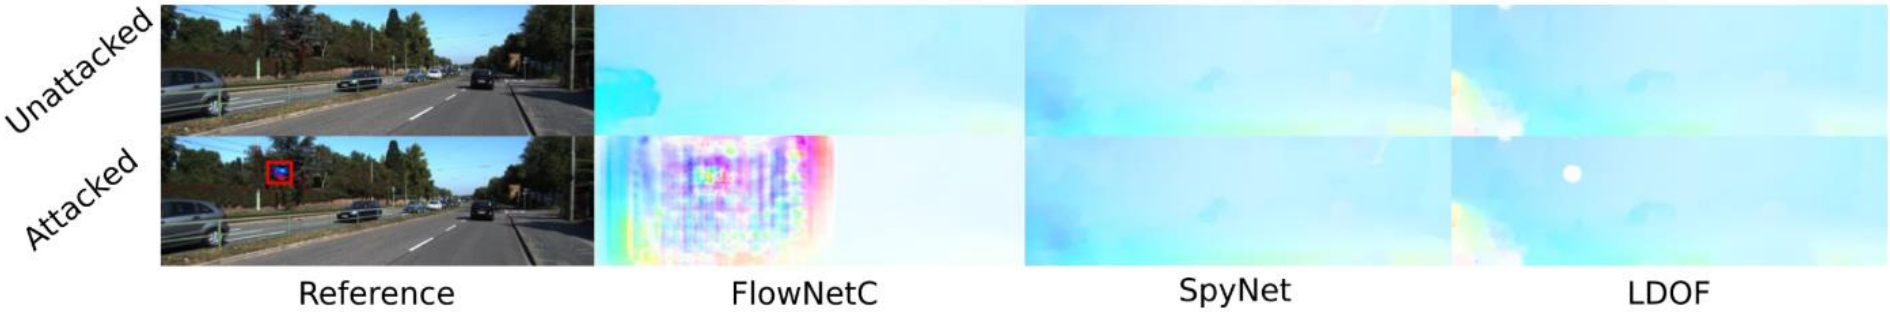

[5]Anurag Ranjan et al. Attacking Optical Flow.2019
[6]https://www.youtube.com/watch?v=5n07loiPmdA

对抗攻防相关实例

- 自动驾驶的隐患：车载识别系统易受干扰

[7] Yue Zhao et al. Seeing isn't Believing: Towards More Robust Adversarial Attack Against Real World Obiect Detectors 2019

对抗攻防相关实例

■ 愚弄AI的隐形衣

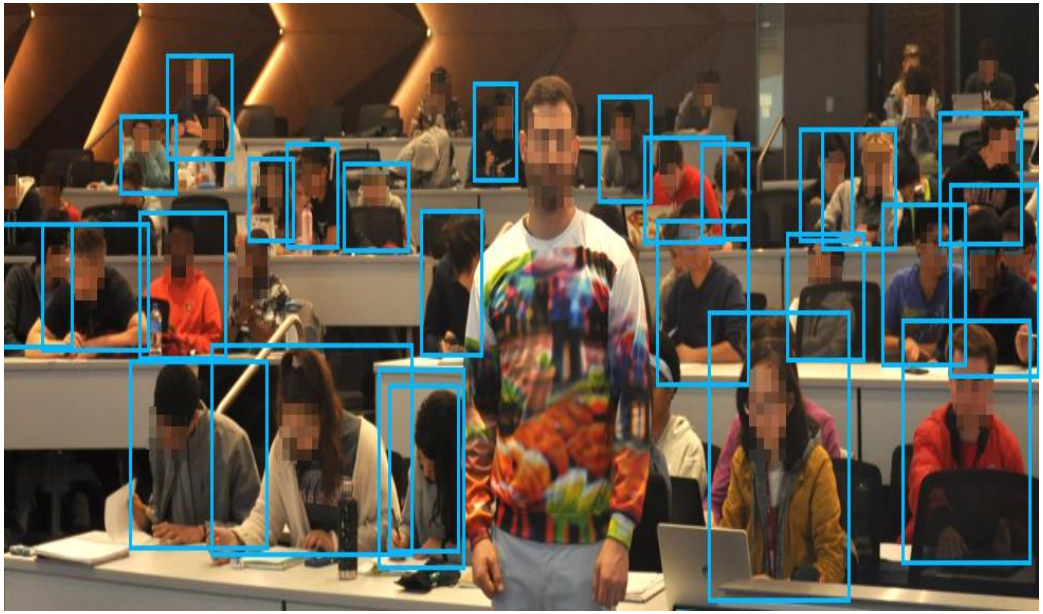

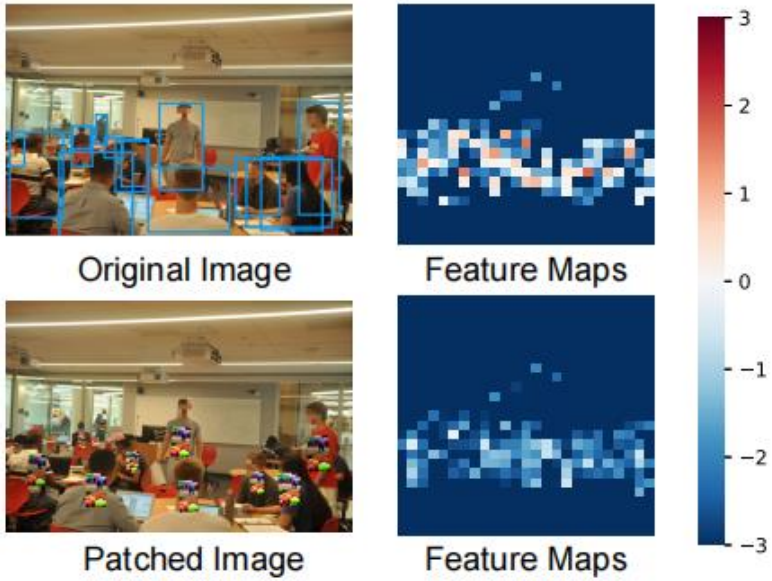

[8] Zuxuan Wu et al. Making an Invisibility Cloak: Real World Adversarial Attacks on Object Detectors. 2019

对抗攻防相关实例

■ 监控摄像头： “瞒天过海”

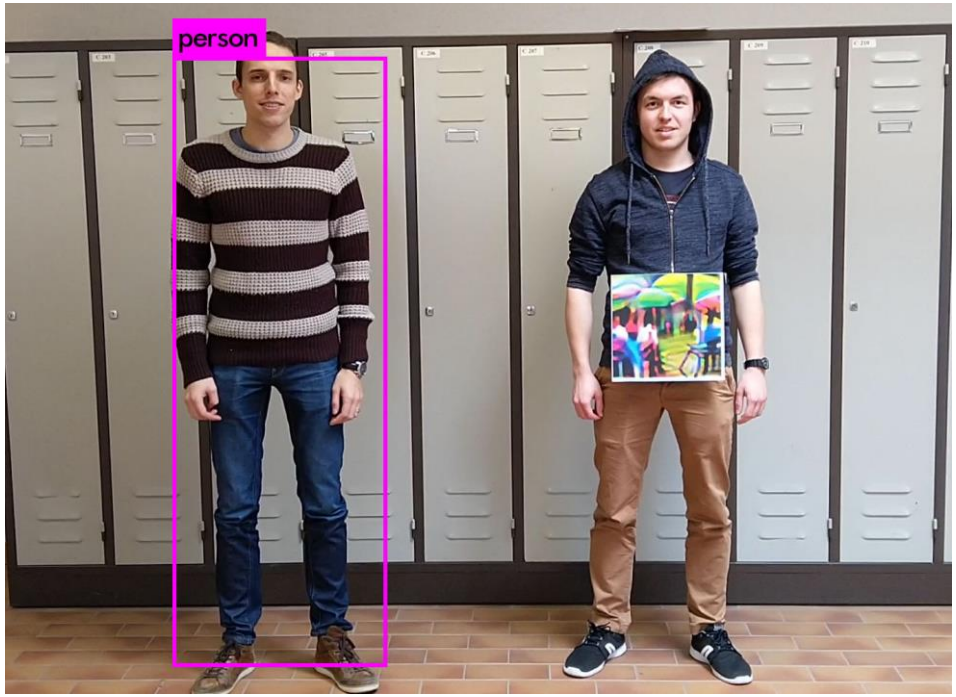

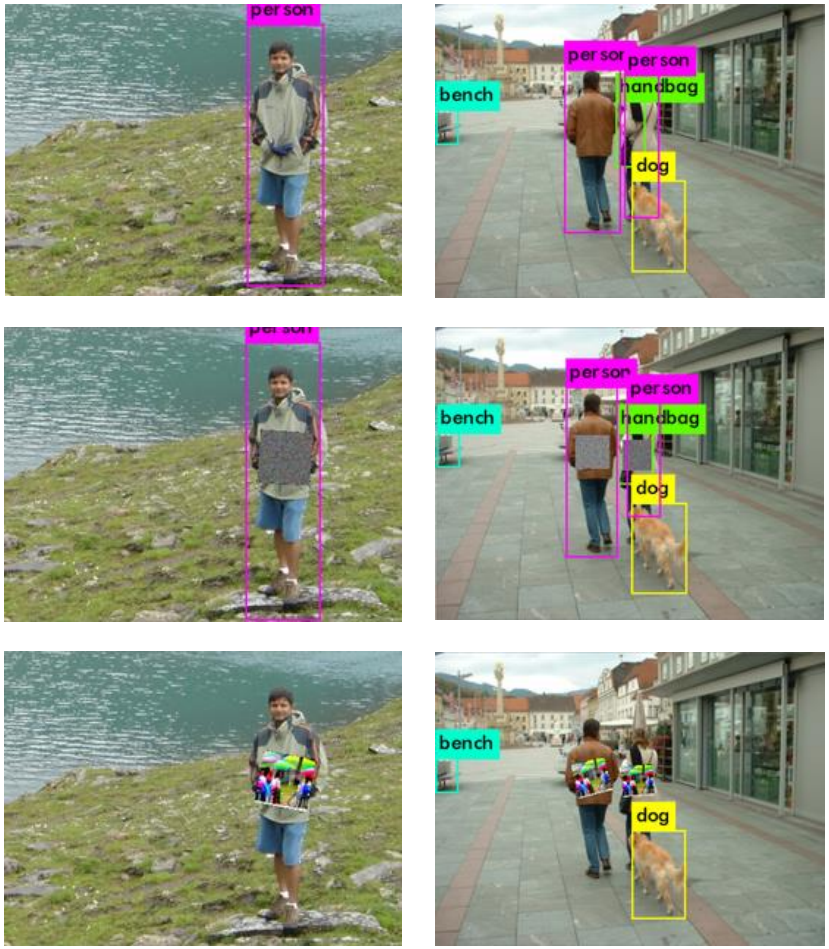

[9] Simen Thys and Wiebe Van Ranst, Fooling automated surveillance cameras: adversarial patches to attack person detection.2019

对抗攻防相关实例

- 仿真3D面具：破解人脸识别系统，微信、支付宝、火车站无一幸免

[10]https://fortune.com/2019/12/12/airport-bank-facial-recognition-systems-fooled/

对抗攻防相关实例

■ 机器阅读理解：问题预测与情感分类

Article: Super Bowl 50
Paragraph: "*Peyton Manning became the first quarterback ever to lead two different teams to multiple Super Bowls. He is also the oldest quarterback ever to play in a Super Bowl at age 39. The past record was held by John Elway, who led the Broncos to victory in Super Bowl XXXIII at age 38 and is currently Denver's Executive Vice President of Football Operations and General Manager. Quarterback Jeff Dean had jersey number 37 in Champ Bowl XXXIV.*"
Question: "*What is the name of the quarterback who was 38 in Super Bowl XXXIII?*"
Original Prediction: John Elway
Prediction under adversary: Jeff Dean

- 插入干扰性文本（对抗样本）
- 改变机器预测结果：
  - 问题答案预测错误（图1）
  - 情感分类预测相反（图2）

Task: Sentiment Analysis. ***Classifier:*** Amazon AWS. ***Original label:*** 100% Negative. ***Adversarial label:*** 89% Positive.

Text: I watched this movie recently mainly because I am a Huge fan of Jodie Foster's. I saw this movie was made right between her 2 Oscar award winning performances, so my expectations were fairly high. ~~Unfortunately~~ **Unf0rtunately**, I thought the movie was ~~terrible~~ **terrib1e** and I'm still left wondering how she was ever persuaded to make this movie. The script is really ~~weak~~ **wea k**.

[11] Jia, R. and Liang, P. Adversarial examples for evaluating reading comprehension systems. 2017

对抗攻防相关实例

■ 语音识别

- ➢ 唤醒Siri，谷歌助手等
- ➢ 添加“噪声”
- ➢ 改变翻译结果

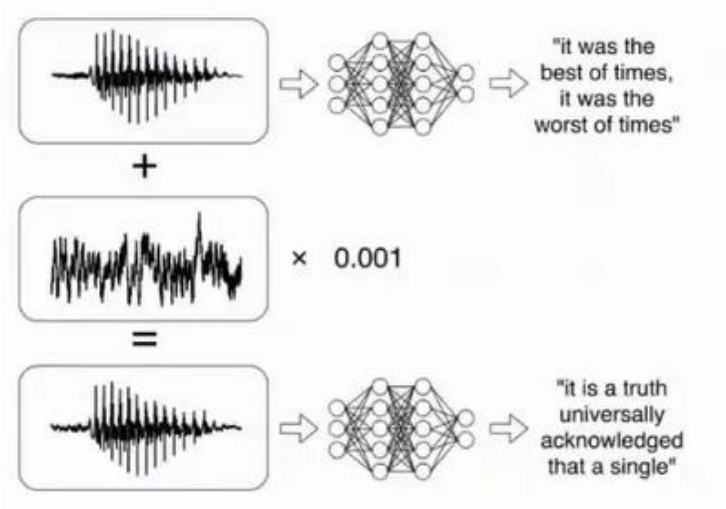

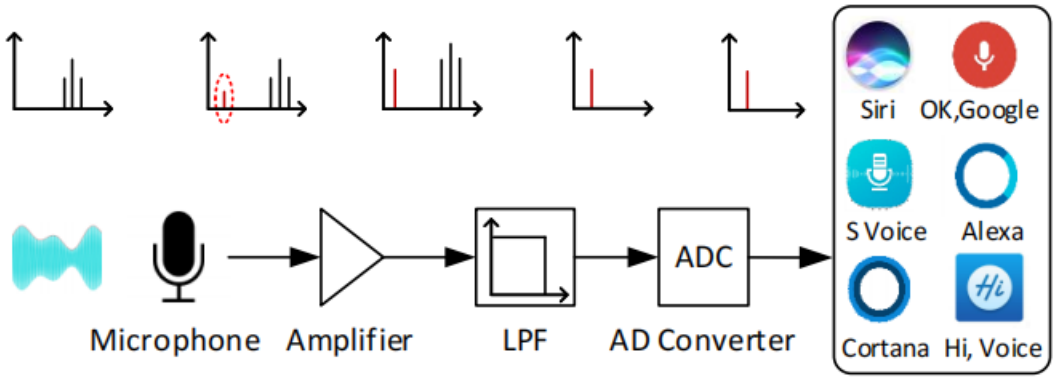

[12]Zhang G, Yan C, Ji X, et al. Dolphinattack: Inaudible voice commands. 2017
[13]https://www.youtube.com/watch?reload=9&v21HF4A3WE4

03| Methods（攻防原理）

AI对抗攻防部分算法原理

对抗攻击基本概念

- 现有的对抗攻击方法主要面向对抗样本的生成方法以及最终达到对模型攻击的成功率。而对抗防御主要分为基于对抗样本的检测与提高模型鲁棒性两个方面。

- **深度学习：**深度学习是一种深层模型，利用多层非线性变换进行特征提取；由低层特性抽取出高层更抽象的表示。主要类型：循环神经网络、深度置信网络、卷积神经网络等。
- **对抗攻击：**通过设计一种有针对性的数值型向量从而让机器学习模型做出误判，这便被称为对抗性攻击。
- **对抗样本：**人为构造的样本。通过对正常样本x添加难以察觉的扰动η，使得分类模型 f 对新生成的样本 x′ 产生错误的分类判断。新生成的对抗样本为：**x′ =x+η。**同时：

$$f(x') \neq f(x), \| x' - x \| \leq \varepsilon$$

- **可迁移性：**类型有：在同一数据集训练的不同模型之间的可迁移性、在不同机器学习技术之间的可迁移性、执行不同任务的模型之间的可迁移性。影响因素：模型类型、对抗样本的攻击力、非目标攻击比目标攻击更容易迁移、数据统计规律。
- **鲁棒性（健壮性）**：控制系统在一定(结构，大小)的参数摄动下，维持其它某些性能的特性。

4.3 Why do they happen(intuitive)

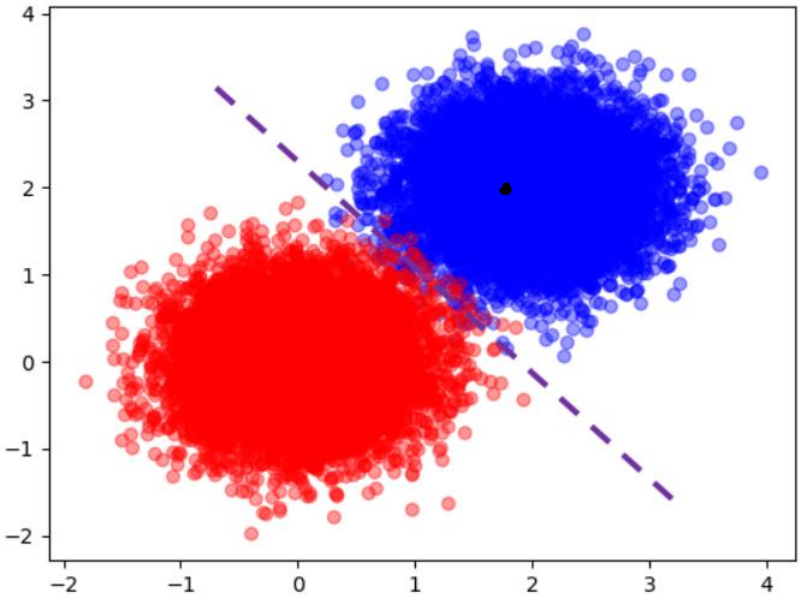

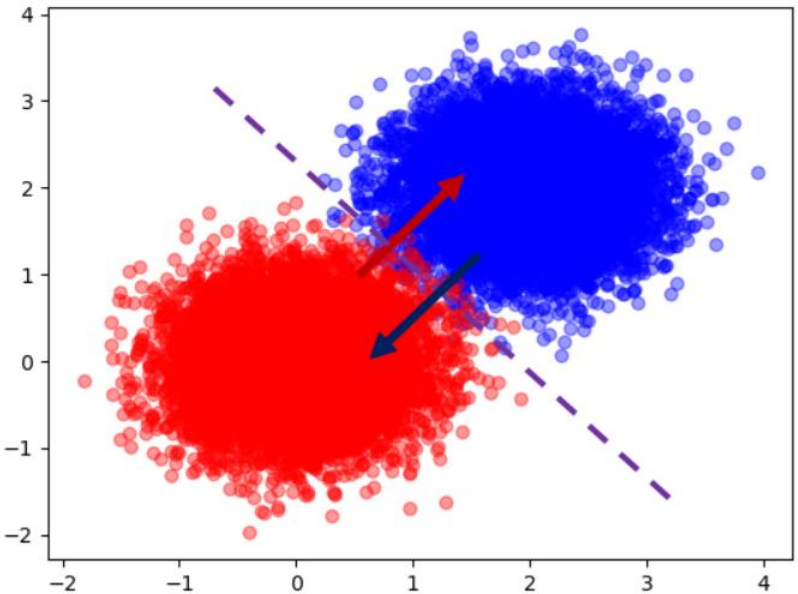

对抗攻击方法分类

- 根据攻击者对目标模型（被攻击的模型）的了解程度不同，已有的对抗攻击大致可以分为两类:白箱攻击和黑箱攻击。

- **白盒攻击：**当算法模型与训练数据都被攻击者所掌握，并且攻击者在此基础上进行的针对性攻击称为白盒攻击。但是很显然，算法模型与训练数据一般都是商业机密，想要获得这些信息是高成本的，也是不太现实的，所以白盒攻击的实用价值受到很大限制。
- **黑盒攻击：**在对算法模型的结构和参数一无所知，甚至相关训练数据也一无所知的情况下，进行攻击的过程称为黑盒攻击。这种情况跟工业界遇到的实际场景较为符合，是工业界关注的重点，也是学术界研究的重点方向。

经典攻击方法

■ FGSM：快速梯度攻击

原理：计算关于输入的损失函数的梯度，将一个选定的小的常数与梯度的符号向量相乘来产生一个小的扰动。

①在白盒环境下，通过求模型对输入的导数

②用符号函数得其梯度方向

③乘以一个步长，得到“扰动”

④攻击样本为原输入加“扰动”

$$\boldsymbol{\eta} = \epsilon \operatorname{sign}\left(\nabla_{\boldsymbol{x}} J(\boldsymbol{\theta}, \boldsymbol{x}, y)\right) \Rightarrow x' = x + \eta$$

其中 η：生成的扰动、ε：控制扰动大小的参数、x：原始样本、x′ ：生成的对抗样本、y：目标标签、θ：网络参数、J：损失函数、▿J(θ,x,y)：相对于输入x损失函数的一阶导数、sign：符号函数(大于0时取1，小于0时取-1)

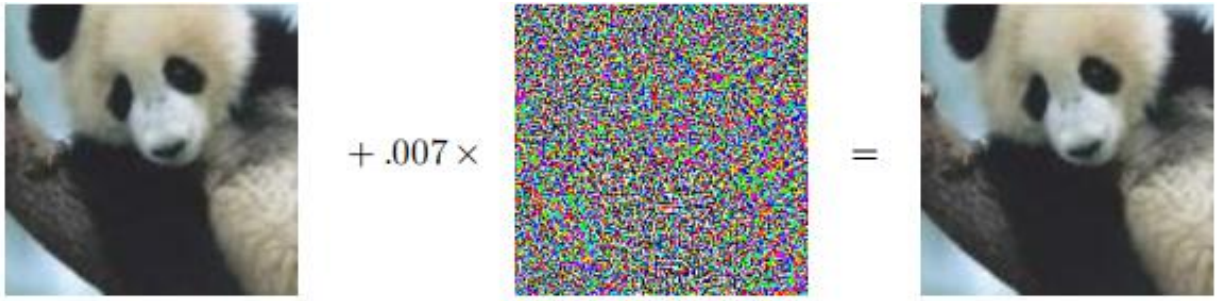

$\boldsymbol{x}$
“panda”
57.7% confidence

$\operatorname{sign}(\nabla_{\boldsymbol{x}} J(\boldsymbol{\theta}, \boldsymbol{x}, y))$
“nematode”
8.2% confidence

$\boldsymbol{x} + \epsilon \operatorname{sign}(\nabla_{\boldsymbol{x}} J(\boldsymbol{\theta}, \boldsymbol{x}, y))$
“gibbon”
99.3 % confidence

4.3 Why do they happen

FAST GRADIENT SIGN METHOD (FGSM) (Goodfellow, Shlens et al. 2014)

Adversarial Perturbation: $\boldsymbol{\eta} = \epsilon \operatorname{sign}\left(\nabla_{\boldsymbol{x}} J(\boldsymbol{\theta}, \boldsymbol{x}, y)\right)$

$\boldsymbol{J}(\boldsymbol{\theta}, \boldsymbol{x}, \boldsymbol{y})$: the cost function to train the neural network($\boldsymbol{\theta}$: the parameters of a model; $\boldsymbol{x}$: the input to the model; $\boldsymbol{y}$: the targets associated with x)
$\boldsymbol{\nabla}$: the gradient of the cost function (the required gradient can be computed efficiently using backpropagation)
$\boldsymbol{\varepsilon}$: small number

$$\operatorname{sgn}(x) := \begin{cases} -1 & \text{if } x < 0, \\ 0 & \text{if } x = 0, \\ 1 & \text{if } x > 0. \end{cases}$$

Adversarial example: $\hat{x} = x + \eta$

$$\boldsymbol{\eta} = \epsilon \operatorname{sign}\left(\nabla_{\boldsymbol{x}} J(\boldsymbol{\theta}, \boldsymbol{x}, y)\right)$$

$$\hat{x} = x + \eta$$

Q1: Why is the formula related to gradient of the cost function?

A: To increase model error → increasing the cost function**.**

Q2: It looks like Gradient Descent Optimization. Isn't it?

$$W_{ij}^{(l)} = W_{ij}^{(l)} - \alpha \frac{\partial}{\partial W_{ij}^{(l)}} J(W, b)$$

$$b_i^{(l)} = b_i^{(l)} - \alpha \frac{\partial}{\partial b_i^{(l)}} J(W, b)$$

对抗样本如何帮助改善机器学习系统?

- 1）改善模型的鲁棒性

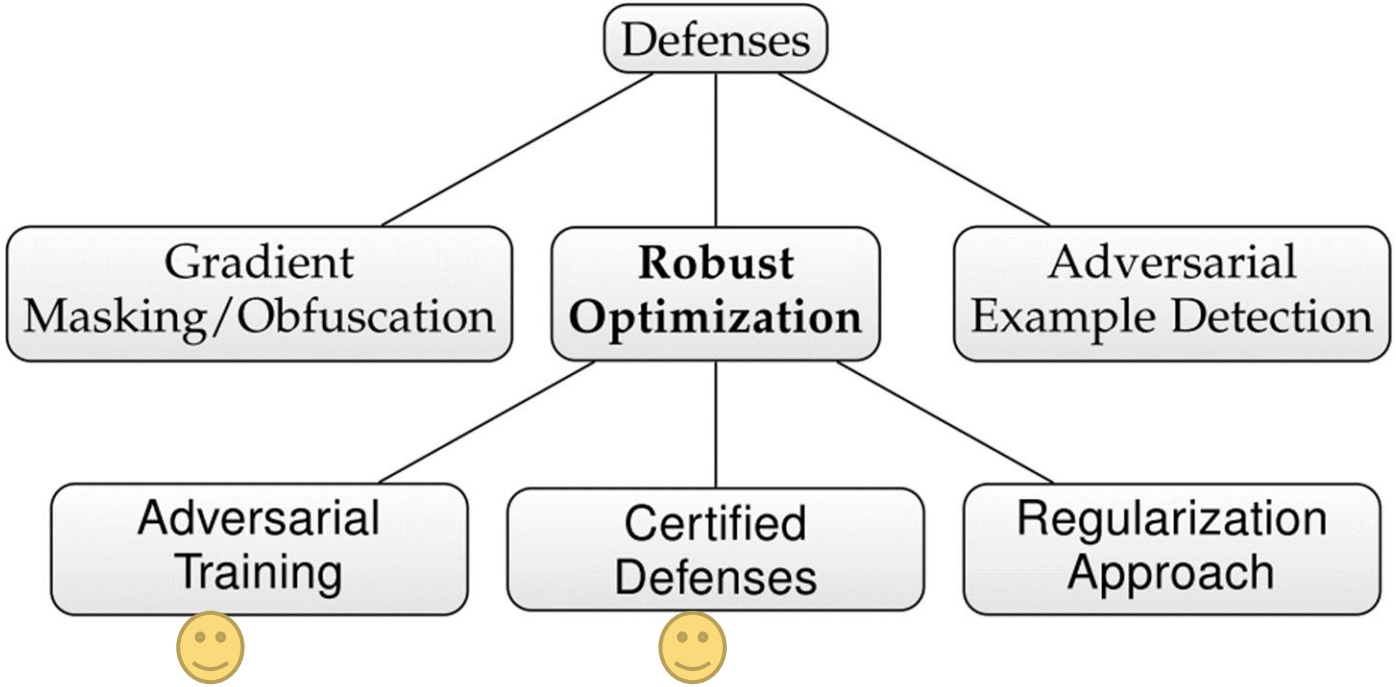

Certified Robustness For ML

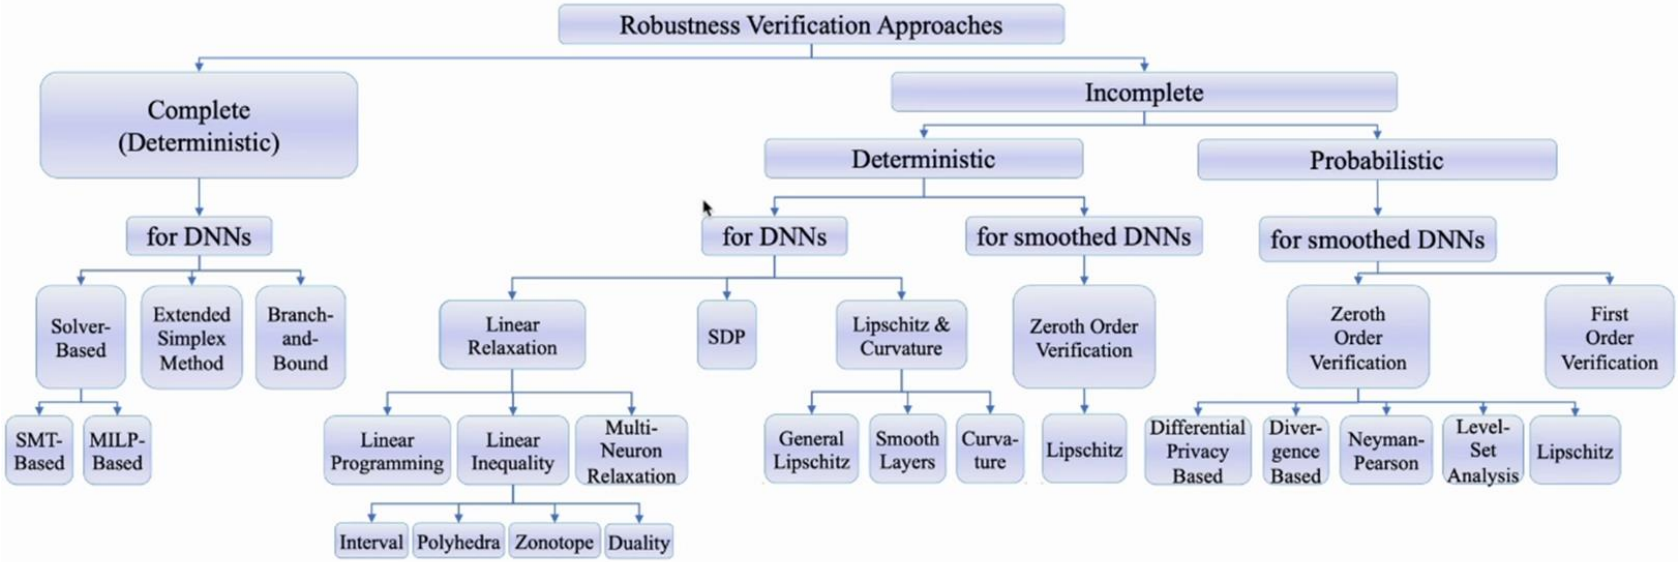

https://sokcertifiedrobustness.github.io/

对抗训练Adversarial Training

An Optimization View on Adversarial Robustness (Madry, Makelov et al. 2018)

$$\min_{\theta} \rho(\theta), \quad \text{where} \quad \rho(\theta) = \mathbb{E}_{(x,y)\sim\mathcal{D}} \left[\max_{\delta\in\mathcal{S}} L(\theta, x+\delta, y) \right]$$

经典防御方法

■ 提高模型鲁棒性的秘密武器——对抗训练

Szegedy在14年的ICLR中提出了对抗样本的概念。对抗样本可以用来攻击和防御，而对抗训练其实是“对抗”家族中防御的一种方式，
其基本原理为：通过添加扰动构建对抗样本，喂入模型一同训练，提高模型遇到对抗样本时的鲁棒性，同时一定程度也能提高模型的表现和泛化能力。
对抗样本一般需要具有两个特点：
①相对于原始输入，所添加的扰动是微小的 ②能使模型犯错

对抗训练的公式如下：

$$\min_{\theta} \rho(\theta), \quad \text{where} \quad \rho(\theta) = \mathbb{E}_{(x,y)\sim\mathcal{D}}\left[\max_{\delta\in\mathcal{S}} L(\theta, x+\delta, y)\right]$$

该过程可以分为两步：
内部的max过程：寻找让模型犯错最大的扰动；
外部的min过程：寻找整体损失最小的参数。

对抗训练的作用：
1. 提高模型应对恶意对抗样本时的鲁棒性。
2. 作为一种正则化方式(regularization)，减少过拟合(overfitting)，提高泛化能力。

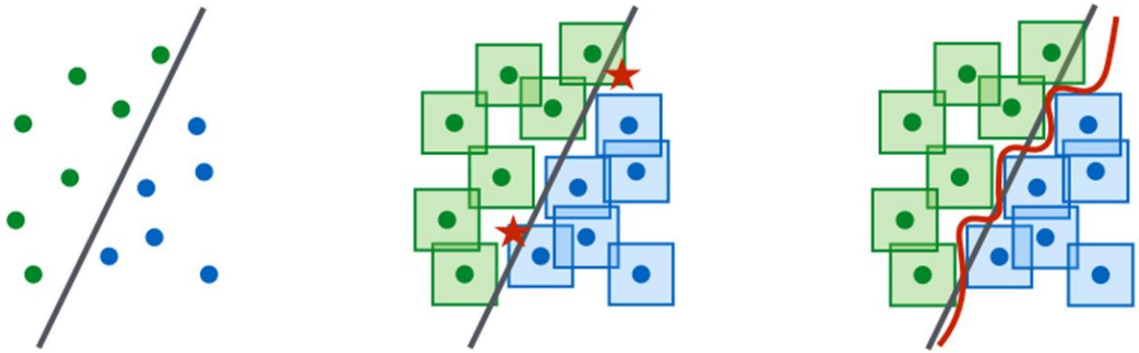

CIFAR10

	Simple	Wide	Simple	Wide	Simple	Wide
Natural	92.7%	95.2%	87.4%	90.3%	79.4%	87.3%
FGSM	27.5%	32.7%	90.9%	95.1%	51.7%	56.1%
PGD	0.8%	3.5%	0.0%	0.0%	43.7%	45.8%

(a) Standard training (b) FGSM training (c) PGD training

1.4 How to use adversarial examples to improve machine learning?
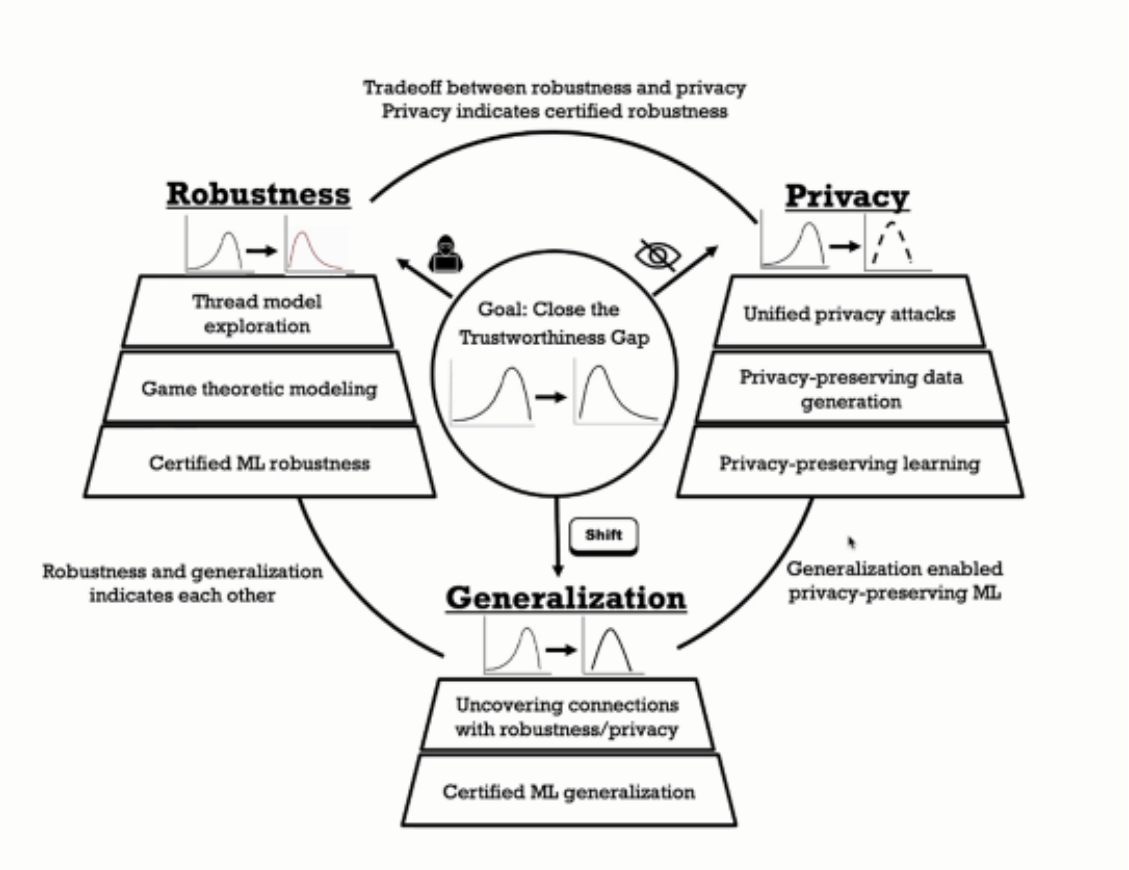
●2）Understand what intelligence is and how the network works